



PROGRAMA DE ASIGNATURA · NIVEL DE GRADO

Machine Learning en Cs Físicas

FIS-3547

Distribución	HT	HP	HI	H-DE	Total
Semanales	1	4	0	9	14
Semestre	16	64	0	144	224

CRÉDITOS

3

Prerrequisitos: FIS-3509

Correquisitos: N/A

Elaborado y/o actualizado por: Erika Montero, MSc., Vladimir Pérez, PhD.

Fecha de última actualización: 2026-07-20

DESCRIPCIÓN DE LA ASIGNATURA

Machine Learning en Ciencias Físicas introduce al estudiante en los métodos del aprendizaje automático como herramienta moderna de análisis y modelado de datos en la física. Partiendo de los fundamentos del aprendizaje estadístico (el compromiso sesgo-varianza, el sobreajuste, la regularización y la generalización), la asignatura desarrolla los métodos de regresión y clasificación, el aprendizaje no supervisado, las redes neuronales artificiales y las arquitecturas profundas, culminando con un panorama de sus aplicaciones en las ciencias físicas: identificación de fases en sistemas de materia condensada, clasificación de eventos en física de partículas, análisis de datos astronómicos, sísmicos y meteorológicos.

La asignatura es de carácter eminentemente práctico: la mayor parte del tiempo de clase se dedica al trabajo directo en computadora con el ecosistema científico de Python (NumPy, pandas, scikit-learn, Keras/TensorFlow y Jupyter), consolidando las destrezas de programación adquiridas en Física Computacional II. Cada unidad combina una exposición teórica breve con sesiones prácticas en las que los métodos se implementan, se evalúan y se aplican a conjuntos de datos de origen físico, con énfasis en la validación rigurosa de modelos, la cuantificación de la incertidumbre y las buenas prácticas de reproducibilidad.

Al finalizar, el estudiante será capaz de formular un problema físico como un problema de aprendizaje automático, seleccionar y entrenar el modelo apropiado, evaluar críticamente sus resultados y comunicarlos con lenguaje científico, competencias de creciente demanda tanto en la investigación en física como en el ejercicio profesional en ciencia de datos.

PERFIL DEL/LOS DOCENTE(S)

El docente debe poseer, como mínimo, título de Maestría en Física, Ciencias de la Computación, Ciencia de Datos, Matemática Aplicada o áreas afines, con formación demostrable en aprendizaje automático y en su aplicación al análisis de datos científicos. Se espera dominio avanzado de Python y de sus bibliotecas científicas (NumPy, pandas, scikit-learn, TensorFlow o PyTorch), experiencia en la enseñanza universitaria con metodologías activas y prácticas de programación, experiencia en investigación o proyectos aplicados de análisis de datos físicos, compromiso con la actualización continua en un campo de rápida evolución y capacidad para orientar proyectos estudiantiles con datos reales.

COMPETENCIAS

Fundamentales

- CF2** Utilizar el razonamiento lógico, creativo, crítico y reflexivo en el análisis de la realidad desde perspectivas variadas, con el propósito de colaborar con la solución de problemas nacionales y globales.
- CF3** Utilizar los recursos tecnológicos disponibles en su área de estudio y desempeño, con la finalidad de realizar eficazmente sus labores en los ámbitos académicos, profesionales y personales.

Genéricas

- CG7** Asumir un comportamiento ético en todas sus actuaciones profesionales y personales para contribuir con la integridad de los procesos institucionales y sociales, la convivencia armoniosa con los demás seres humanos, y la protección del ambiente.

Específicas

- CE5** Utilizar simulaciones y una variedad de herramientas e instrumentos tecnológicos y computacionales para investigar y analizar fenómenos y problemas físicos, destacando en la aplicación de técnicas modernas del campo.
- CE6** Analizar y utilizar los conceptos, principios, técnicas, métodos y lenguaje de la matemática, empleando metodologías diversas para proponer solución a los problemas y expresar leyes y modelos de la Física.
- CE7** Analizar fenómenos de manera colaborativa con pares de otras áreas del conocimiento, utilizando conceptos y métodos propios de las ciencias para resolver problemas y comunicar resultados.

RESULTADOS DE APRENDIZAJE ESPERADOS

- RAE-1** Explicar los conceptos fundamentales del aprendizaje estadístico (compromiso sesgo-varianza, sobreajuste, regularización y generalización) y aplicarlos a la validación de modelos entrenados con datos físicos.
- RAE-2** Implementar en Python modelos de regresión lineal, polinómica y regularizada para ajustar datos experimentales y de simulación, evaluando su capacidad predictiva mediante validación cruzada.
- RAE-3** Construir y comparar clasificadores (regresión logística, máquinas de vectores de soporte, árboles de decisión y métodos de ensamble) sobre conjuntos de datos físicos, empleando métricas de desempeño apropiadas.
- RAE-4** Aplicar técnicas de aprendizaje no supervisado (reducción de dimensionalidad, agrupamiento y detección de anomalías) para explorar la estructura de datos físicos de alta dimensión.
- RAE-5** Diseñar y entrenar redes neuronales artificiales mediante retropropagación y descenso de gradiente estocástico, seleccionando arquitectura, funciones de activación y técnicas de regularización adecuadas al problema.
- RAE-6** Utilizar arquitecturas profundas especializadas (redes convolucionales, redes recurrentes y autoencoders) para clasificar imágenes, analizar series temporales y comprimir datos de origen físico.
- RAE-7** Desarrollar un proyecto integrador de aprendizaje automático aplicado a un problema de las ciencias físicas, documentando el flujo de trabajo completo de forma reproducible y comunicando los resultados con lenguaje científico.

CONTENIDO

Unidad 1: Fundamentos del aprendizaje estadístico

Qué es el aprendizaje automático: aprendizaje supervisado, no supervisado y por refuerzo; el flujo de trabajo de un proyecto de datos; conjuntos de entrenamiento, validación y prueba; compromiso sesgo-varianza; sobreajuste y subajuste; regularización y generalización; descenso de gradiente; repaso del ecosistema científico de Python: NumPy, pandas, Matplotlib y Jupyter; preparación, limpieza y visualización de datos físicos

Unidad 2: Regresión

Regresión lineal en notación matricial; método de mínimos cuadrados; regresión polinómica; regularización ridge y LASSO; validación cruzada y selección de hiperparámetros; interpretación estadística del ajuste; aplicación: ajuste de leyes físicas y calibración de instrumentos con scikit-learn

Unidad 3: Clasificación

Regresión logística; k vecinos más cercanos; máquinas de vectores de soporte y funciones núcleo; árboles de decisión; métodos de ensamble: bosques aleatorios y potenciación de gradiente; métricas de desempeño: matriz de confusión, precisión, exhaustividad, F1 y curvas ROC; desbalance de clases; aplicación: clasificación de fases del modelo de Ising y de eventos en física de partículas

Unidad 4: Aprendizaje no supervisado

Reducción de dimensionalidad: análisis de componentes principales (PCA) y t-SNE; agrupamiento: k-means, jerárquico y DBSCAN; detección de anomalías; visualización de datos de alta dimensión; aplicación: exploración de espectros, catálogos astronómicos y registros geofísicos

Unidad 5: Redes neuronales artificiales

Del perceptrón a las redes densas multicapa; funciones de activación; la red neuronal como aproximador universal; retropropagación; descenso de gradiente estocástico y sus variantes; regularización de redes: dropout, parada temprana y aumento de datos; construcción y entrenamiento de redes con Keras/TensorFlow; monitoreo del entrenamiento y ajuste de hiperparámetros

Unidad 6: Aprendizaje profundo y arquitecturas especializadas

Redes neuronales convolucionales: capas de convolución y agrupamiento; clasificación de imágenes científicas; redes recurrentes y análisis de series temporales físicas; autoencoders y compresión de datos; introducción a los modelos generativos; transferencia de aprendizaje

Unidad 7: Aprendizaje automático en las ciencias físicas y proyecto integrador

Panorama de aplicaciones: materia condensada, física de partículas, astrofísica, geofísica y ciencias de la atmósfera; interpretabilidad de modelos; cuantificación de incertidumbre; sesgos de los datos, ética y reproducibilidad; gestión de versiones y documentación del flujo de trabajo; desarrollo, redacción y defensa del proyecto final con datos físicos reales

ESTRATEGIAS Y ACTIVIDADES FORMATIVAS

E.1	Clase expositiva del docente: Exposición organizada y rigurosa de los fundamentos teóricos de la unidad.
E.2	Aprendizaje basado en problemas (ABP): Resolución de problemas teóricos y aplicados que exigen integrar los conceptos de la unidad.
E.10	Demostraciones y simulaciones en clase: Uso de demostraciones y simulaciones numéricas para visualizar conceptos abstractos.
E.13	Preguntas guías de lectura: Preguntas orientadoras que enfocan la lectura previa y preparan la discusión.
E.18	Resolución de ejercicios y problemas: Práctica sistemática de ejercicios para consolidar procedimientos de cálculo y modelado.

EVALUACIÓN DE LOS APRENDIZAJES

Criterios

C.1	Nivel de dominio de los conceptos y procedimientos.
C.2	Aplicación de conceptos y procedimientos a la resolución de problemas.
C.3	Capacidad de análisis, comprensión y síntesis.
C.4	Habilidades de comunicación científica, oral y escrita.
C.5	Uso efectivo de herramientas computacionales y de simulación.

Técnicas e instrumentos

Técnica	Instrumentos	Criterios
TE.1 Pruebas escritas u orales	Exámenes parciales y final; Pruebas cortas (quizzes)	C.1 C.2
TE.3 Trabajos escritos, individuales o en grupo	Ejercicios y asignaciones; Proyectos (individuales o colaborativos)	C.2 C.3 C.5
TE.2 Exposiciones y presentaciones orales	Exposiciones y defensas orales	C.4

La evaluación es formativa, continua e integral (Res. 2021-227 y Res. 2003-084). Se aplican al menos dos evaluaciones parciales; ninguna prueba escrita puede exceder el 40 % de la puntuación total (Res. 72-346). La ponderación detallada se especifica en la guía didáctica de la asignatura.

RECURSOS DIDÁCTICOS Y TECNOLÓGICOS

Didácticos

- R1 Bibliografía académica: Libros de texto, manuales, artículos científicos y bases de datos.
- R2 Materiales de apoyo: Guías, cuadernos de laboratorio y colecciones de ejercicios.
- R3 Recursos digitales: Videos educativos, simulaciones interactivas, infografías y presentaciones.

Tecnológicos

- R7 Equipos digitales: Computadoras y dispositivos con acceso a internet.
- R8 Software especializado: Python, MATLAB, R, simuladores y entornos de desarrollo (Jupyter).
- R4 Plataformas educativas: Sistemas de gestión del aprendizaje (Moodle, Blackboard, edX).
- R11 Conectividad en clases: Acceso a internet en el aula o espacio de enseñanza.

REFERENCIAS BIBLIOGRÁFICAS

Básicas

- Géron, A. (2022). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems (3.^a ed.). O'Reilly Media.
- Acquaviva, V. (2023). Machine learning for physics and astronomy. Princeton University Press.
- Mehta, P., Bukov, M., Wang, C.-H., Day, A. G. R., Richardson, C., Fisher, C. K., & Schwab, D. J. (2019). A high-bias, low-variance introduction to machine learning for physicists. Physics Reports, 810, 1-124.

Complementarias

- Bishop, C. M., & Bishop, H. (2024). Deep learning: Foundations and concepts. Springer.
- Carleo, G., Cirac, I., Cranmer, K., Daudet, L., Schuld, M., Tishby, N., Vogt-Maranto, L., & Zdeborová, L. (2019). Machine learning and the physical sciences. Reviews of Modern Physics, 91(4), 045002.
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in Python. Springer.